

Laporan Proyek

Judul: Amazon Product Review Analysis and Prediction

Kelompok: 2

Anggota:

1. Muhammad Arsyad Setiawan : 245150207111052
2. Rionaldi Suhandafa : 245150200111045
3. Rimba Nevada : 245150201111013
4. Muhammad Faiz Majid : 245150201111003

1. Latar belakang

Dalam era digital saat ini, platform perdagangan elektronik (e-commerce) seperti Amazon telah bertransformasi menjadi sumber informasi utama bagi konsumen sebelum melakukan keputusan pembelian. Ulasan pelanggan (customer reviews) yang ditinggalkan pada platform tersebut memuat opini dan umpan balik yang sangat berharga untuk menganalisis peluncuran produk elektronik serta mengevaluasi tingkat kepuasan pelanggan. Namun, seiring dengan ukuran data yang masif, seperti dataset Consumer Reviews of Amazon Products yang mencapai 34.660 baris, proses ekstraksi informasi secara manual menjadi sangat tidak efisien. Oleh karena itu, pendekatan komputasional berbasis Natural Language Processing (NLP) dan Machine Learning untuk analisis sentimen sangat diperlukan guna mengklasifikasikan polaritas opini menjadi kategori positif, netral, maupun negatif secara otomatis.

Dalam pengembangan model klasifikasi teks pada data ulasan dunia nyata, terdapat dua tantangan utama: kualitas data tekstual yang dipenuhi noise dan fenomena ketidakseimbangan kelas (class imbalance). Distribusi ulasan seringkali sangat asimetris dan didominasi oleh kelas positif, sehingga model pembelajaran mesin standar cenderung menjadi bias dan gagal mengenali pola pada kelas minoritas. Untuk mengatasi permasalahan tekstual, penelitian ini menerapkan pipeline prapemrosesan tingkat lanjut menggunakan pustaka NLTK (Natural Language Toolkit) guna melakukan pembersihan tanda baca, penghapusan kata hubung (stop-words removal), dan normalisasi kata (lemmatization).


Lebih lanjut, untuk memitigasi bias akibat ketidakseimbangan kelas, proyek ini mengusulkan dan membandingkan efektivitas berbagai strategi penyeimbangan data. Eksperimen dilakukan dengan menguji teknik pemotongan data kelas mayoritas (Random Under-sampling), sintesis data buatan pada kelas minoritas (Over-sampling melalui metode SMOTE), serta modifikasi fungsi penalti algoritma melalui pembobotan kelas (Class Weight). Guna mencapai kapabilitas klasifikasi yang maksimal, eksplorasi pemodelan tidak hanya terbatas pada algoritma standar (seperti Logistic Regression, Support Vector Machine, dan LightGBM), namun juga mengimplementasikan optimasi lanjutan. Secara spesifik, penelitian ini menerapkan pencarian ruang parameter yang efisien menggunakan kerangka kerja Optuna (Hyperparameter Tuning) pada algoritma Random Forest, untuk menanggulangi accuracy paradox dan menghasilkan model yang memiliki tingkat generalisasi serta Macro F1-Score yang paling optimal.

2. Penjelasan Dataset

Dataset yang digunakan dalam proyek ini adalah Consumer Reviews of Amazon Products, yang memuat ulasan pelanggan terkait produk-produk elektronik Amazon (seperti Kindle, Fire TV Stick, dan lain-lain). Data ini bersumber dari Datafiniti's Product Database dan sering digunakan untuk menganalisis peluncuran produk elektronik serta melatih model Machine Learning untuk analisis sentimen. Ukuran Data: Dataset ini terdiri dari 34.660 baris (entri ulasan) dan 21 kolom atribut. Fitur/Atribut Penting: Beberapa fitur utama yang digunakan dalam analisis antara lain:

- reviews.rating: Nilai bintang yang diberikan pengguna (skala 1-5).
- reviews.text: Isi ulasan pelanggan dalam bentuk teks.
- reviews.title: Judul ulasan pelanggan.
- reviews.date: Tanggal ulasan dibuat.

Untuk melakukan klasifikasi sentimen review produk, kami melakukan proses binning pada kolom reviews.rating dengan aturan rating ≤ 2 , maka dikategorikan sebagai negatif, lalu jika rating $= 3$, maka dikategorikan sebagai netral, dan terakhir jika rating > 3 maka dikategorikan sebagai positif. Hasil distribusi target dapat dilihat pada gambar di bawah berikut.



Gambar 1: Distribusi target data

Dapat dilihat pada gambar 1, distribusi kelas tidak seimbang. Selain itu juga terdapat beberapa kolom dengan banyak missing values, seperti reviews.didPurchase (1 non-null), reviews.userCity (0 non-null), dan reviews.userProvince (0 non-null). Oleh karena itu, dalam tahap preprocessing data, dilakukan missing value handling, Case Inconsistency handling, Punctuation noise handling, dan dilakukan Undersampling untuk kelas target kelas positif. Setelah data sudah bersih, maka baru akan dilakukan feature engineering dengan teknik teknik di berikut:

1. Fitur Independen:
 - VADER Sentiment
 - POS Tagging
 - Flesch Reading Ease
 - Words Count
 - Text Length
2. Fitur Dependen:
 - TF-IDF
 - Bag-of-Words
 - LDA Topic Features

3. Metodologi

Metodologi yang dipakai yaitu menggunakan Machine Learning berbasis Natural Language Processing (NLP) untuk mengklasifikasikan ulasan teks ke dalam sentimen polaritas. Bagian NLP disini murni sebagai feature extractor atau mengambil informasi dari sebuah teks sehingga bisa dipakai untuk modeling ML.

3.1. Pemrosesan Label Data

Data bersumber dari dataset Consumer Reviews of Amazon Products yang memiliki 34.660 baris dan 21 atribut. Sebelum preprocessing text, atribut reviews.rating dikonversi menjadi target sentimen menggunakan metode binning diskrit dengan aturan: rating ≤ 2 dikategorikan sebagai "Negatif", rating 3 sebagai "Netral", dan rating >3 sebagai "Positif".

3.2. Text Preprocessing

Untuk menangani noise tekstual dan inkonsistensi struktur, data teks mentah dibersihkan menggunakan pipeline pra-pemrosesan berurutan. Langkah-langkah tersebut meliputi:

- **Penanganan Missing Values:** Menghapus fitur yang memiliki persentase data kosong lebih dari 50% (seperti userCity dan userProvince) serta menghapus baris ulasan yang kosong.
- **Pembersihan Tanda Baca dan Inkonsistensi:** Menyeragamkan teks menjadi huruf kecil (case folding) dan mengganti seluruh karakter non-alfanumerik dengan spasi menggunakan manipulasi Regular Expression (RegEx).
- **Tokenisasi dan Normalisasi (NLTK):** Teks dipecah menjadi token. Proses penghapusan stop-words dilakukan dengan hati-hati, di mana kata-kata negasi (seperti not, nor, don't) dipertahankan agar tidak menghilangkan makna konteks sentimen. Selanjutnya, dilakukan Lemmatization menggunakan WordNetLemmatizer untuk mengembalikan kata ke bentuk dasar (misalnya kata kerja atau kata benda).

3.3. Feature Engineering

Karena model Machine Learning tidak dapat memproses teks secara langsung, library berikut ini melakukan extraction feature atau mengekstraksi kombinasi fitur independen berbasis leksikon dan statistik, serta representasi fitur dependen tekstual:

Fitur Independen Numerik: Menghitung jumlah kata (Word Count), panjang teks (Text Length), skor Flesch Reading Ease untuk mengukur tingkat keterbacaan, rasio Part-of-Speech (POS) untuk kata benda dan kata kerja, serta ekstraksi skor sentimen majemuk menggunakan kamus leksikon VADER. Seluruh fitur numerik distandardisasi menggunakan MinMaxScaler.

- **Fitur Dependen Representasi Teks:** Teks ulasan dikonversi ke dalam vektor spasial matematis menggunakan skema pembobotan Term Frequency-Inverse Document Frequency (TF-IDF) yang dibatasi pada rentang N-gram 1 hingga 2 dengan maksimal 5.000 fitur terbaik.
- **Ekstraksi Fitur Topik:** Implementasi algoritma Latent Dirichlet Allocation (LDA) pada representasi Bag-of-Words (BoW) untuk mendeteksi sebaran distribusi topik tersembunyi ke dalam probabilitas matematis. Seluruh komponen fitur ini kemudian digabungkan (di-stack secara horizontal) menjadi satu matriks representasi data tunggal.

3.4. Mitigasi Ketidakseimbangan Kelas

Berdasarkan eksplorasi data, kelas ulasan didominasi oleh kelas "Positif" yang memicu ketidakseimbangan yang masif. Eksperimen membandingkan tiga metode resampling dan penalti:

- **Random Undersampling:** Pemotongan sampel secara acak pada kelas mayoritas (Positif) menjadi ukuran yang jauh lebih kecil (misalnya 900 observasi) guna memaksa model mempelajari variasi dari minoritas.
- **Synthetic Minority Over-sampling Technique (SMOTE):** Membentuk data latih buatan (sintetis) dengan menginterpolasi fitur kelas minoritas pada ruang dimensi k-nearest neighbors.
- **Class Weighting:** Mengubah parameter fungsi objektif/penalti algoritma, di mana kelas dengan kemunculan sedikit diberikan kompensasi bobot (weight) matematis yang lebih tinggi selama proses pembelajaran.

3.5. Pemodelan dan Optimasi Hyperparameter

Untuk mencari kemampuan deteksi sentimen yang maksimal, enam algoritma dikomparasi secara luas yaitu Naive Bayes, Logistic Regression, Support Vector Machine (SVM), Random Forest, XGBoost, dan LightGBM. Proses pelatihan menggunakan teknik Stratified K-Fold Cross Validation (3 splits) untuk memastikan proporsi data terjaga. Serta kami menerapkan Hyperparameter tuning probabilitas dengan menggunakan library Optuna dengan 80 percobaan (trials). Setiap model dilatih agar menghasilkan kombinasi kedalaman pohon, learning rate, maupun fungsi penalti yang paling optimal terhadap fungsi objektif.

3.6. Metrik Evaluasi

Sehubungan dengan sindrom paradoks akurasi yang terjadi saat menganalisis data imbalanced, proyek ini tidak menjadikan metrik Accuracy standar sebagai acuan akhir. Kemampuan model dievaluasi secara ketat berdasarkan:

- **Macro F1-Score:** Menyeimbangkan perhitungan skor presisi (Precision) dan sensitivitas (Recall) secara agregat (rata-rata unweighted) di seluruh kelas sentimen.
- **Confusion Matrix:** Digunakan untuk mengidentifikasi "kebingungan model" (misclassifications)—khususnya seberapa sering model gagal mengidentifikasi kelas netral dan memprediksinya sebagai sentimen negatif atau positif.
- **Learning Curves:** Evaluasi secara visual untuk memeriksa varians di antara skor pelatihan dan pengujian guna mengidentifikasi kecenderungan Overfitting atau Underfitting.

4. Hasil dan Pembahasan

Eksperimen pemodelan dilakukan secara komprehensif melalui perbandingan berbagai algoritma klasifikasi (Machine Learning) dengan memanfaatkan representasi fitur teks TF-IDF (dibatasi pada 5.000 fitur terbaik) dan rasio pembagian data latih-uji sebesar 80:20. Untuk menangani dominasi sampel sentimen positif pada dataset, eksperimen ini mengeksekusi beberapa skenario strategi penanganan data tidak seimbang, serta mengintegrasikan optimasi hyperparameter tingkat lanjut.

4.1. Baseline : Undersampling + NLTK

Distribusi kelas setelah undersampling:


- Negatif 590
- Netral 1176
- Positif 1200

Metrik Evaluasi	Hasil
Macro F1	0.5466
Accuracy	0.8269

Table 1 : Hasil evaluasi experiment 1

Class	Precision	Recall	F1-Score	Support
Negatif	0.41	0.53	0.46	148
Netral	0.17	0.69	0.27	294
Positif	0.99	0.84	0.91	6371

Table 2 : Classification report experiment 1



Gambar 2: Confusion matrix experiment 1

Model menunjukkan performa yang sangat tidak seimbang antar kelas. Kelas Positif diprediksi dengan sangat baik karena mendominasi data, sementara kelas Netral dan Negatif performanya jauh lebih rendah akibat jumlah sampelnya yang sedikit. Ini bisa dilihat dari Macro F1 sebesar 0.55 yang relatif rendah dibanding accuracy 0.83 yang berarti model hanya efektif untuk memprediksi Positif tapi kurang mampu mengenali Negatif dan Netral dengan baik.

4.2. LightGBM : Random Oversampling + Class Weight

Distribusi Kelas Setelah Oversampling :

- Negatif 25.485
- Netral 25.485
- Positif 25.485


Metric evaluasi	Result
Test F1 (macro)	0.5750

Accuracy	0.9300
----------	--------

Table 3 : Hasil evaluasi experiment 2

Class	Precision	Recall	F1-Score	Support
Negatif	0.46	0.47	0.47	148
Netral	0.33	0.26	0.29	294
Positif	0.96	0.97	0.97	6371

Table 4 : Classification report experiment 2



Gambar 3: Confusion matrix experiment 2

Hasil eksperimen ini masih belum mendapatkan hasil yang optimal, dilihat dari macro f1 nya yang masih di angka 0.57 dan accuracy 0.93. Model masih sangat bias yang disebabkan oleh imbalanced data. Sehingga dilanjutkan ke eksperimen yang selanjutnya.

4.3. Ensemble (XGB, LGBM): Weighted Class


Pada eksperimen ke-3 ini, menggunakan Ensemble Voting, dimana XGBoost memiliki bobot lebih tinggi yaitu 0.6, sedangkan LightGBM hanya 0.4.

Metric evaluasi	Result
Test F1 (macro)	0.5795
Accuracy	0.9392

Table 5 : Hasil evaluasi experiment 3

Class	Precision	Recall	F1-Score	Support
Negatif	0.50	0.45	0.47	148
Netral	0.41	0.23	0.29	294
Positif	0.96	0.98	0.97	6371

Table 5 : Classification report experiment 3



Gambar 4: Confusion matrix experiment 3

4.4. Random Forest: Weighted Class + Undersampling + Optuna

Distribusi Kelas Setelah Undersampling:

- Netral 1.499
- Positif 900
- Negatif 812

Hasil pembobotan kelas sebagai berikut:


- Kelas 0 (Negatif): $w_0 = \frac{3211}{3 \times 812} = \frac{3211}{2436} \approx 1.3181$
- Kelas 1 (Netral): $w_1 = \frac{3211}{3 \times 1499} = \frac{3211}{4497} \approx 0.7140$
- Kelas 2 (Positif): $w_2 = \frac{3211}{3 \times 900} = \frac{3211}{2700} \approx 1.1893$

Metric evaluasi	Result
Train Acc	0.99
Test Acc	0.70
Test F1 (macro)	0.70
Test Precision (macro)	0.71
Test Recall (macro)	0.70


Table 6 : Hasil evaluasi experiment 4

Class	Precision	Recall	F1-Score	Support
Negatif	0.67	0.64	0.65	163
Netral	0.70	0.73	0.71	300
Positif	0.77	0.74	0.75	180

Table 7 : Classification report experiment 4




Gambar 5: Confusion matrix experiment 4



Gambar 6: Learning curve experiment 4

Experiment keempat menunjukan performa paling baik di antara experiment experiment sebelumnya dengan menghasilkan parameter terbaik dari optuna sebagai berikut: 'n_estimators': 333, 'max_depth': 43, 'max_features': 'sqrt', 'min_samples_split': 5, 'min_samples_leaf': 1, 'bootstrap': False. Meskipun begitu, jika dilihat pada learning curve pada gambar n, model random forest ini masih mengalami overfitting. Tidak hanya itu, Jika dilihat pada classification report, model masih sulit mengidentifikasi sentimen negatif, hal ini dapat dilihat pada grafik di bawah ini.



Setelah kami lakukan analisis lebih lanjut, penyebab dari kurang baiknya performa model ini adalah bersumber dari dataset amazon ini sendiri yang dimana, text sentiment kelas netral tidak begitu berbeda jauh dengan kelas lainnya seperti yang ditunjukkan pada tabel di bawah ini.

Raw Text	Actual	Predicted
So far so good Ordering process was easy and as expected. Hopefully my husband will install it soon.	Netral	Positif
It's ok, but it jump pages too easily. I had a lower end kindle for years. When that broke, I decide to buy the	Netral	Negatif

higher end one that is backlit. The back litghting is nice for reading at night. But the touch features are too jumpy--it jumps pages instead of just turning to the next one. It is cumbersome to buy through amazon and difficult to see the list of what you have. I don't know if I'd buy this one over the lowest end one again.		
--	--	--

5. Kesimpulan

Proyek ini bertujuan mengklasifikasikan sentimen ulasan produk Amazon menjadi tiga kelas yaitu Positif, Netral, Negatif menggunakan berbagai strategi machine learning. Dari empat eksperimen yang dilakukan, performanya terus meningkat dari Baseline hingga eksperimen yang menggunakan Random Forest yang ditambah dengan Optuna. Eksperimen terbaik adalah experiment keempat yang menggabungkan undersampling, class weighting, dan hyperparameter tuning via Optuna pada Random Forest, menghasilkan performa yang jauh lebih seimbang antar kelas. Namun model masih mengalami overfitting dan kesulitan membedakan kelas Netral, yang disebabkan oleh karakteristik teks Netral pada dataset Amazon yang secara linguistik memang ambigu dan mirip dengan kelas lainnya.

6. Tautan GitHub Project

URL Repositori:

<https://github.com/arsyad429/Amazon-product-sentiment-analysis-and-classification.git>